



CLASIFICAREA FRUCTELOR

Coordonator licență: Conf. Dr. Ignat Anca
Absolvent: Burluc Laurențiu-Valentin

MOTIVAȚIE

Clasificarea soiurilor și
tipurilor de fructe

Dorința de a explora un nou
domeniu și de a testa
diferite configurații pentru a
observa cum se comportă
modelele în anumite cazuri

DESCRIERE SOLUȚIE

Scopul este cel de a obține o clasificare cât mai precisă cu diferite seturi de imagini.


Modul de rezolvare:

- ❖ Arhitecturi
 - Un model de rețea neuronală convoluțională
 - Transfer de învățare prin VGG-16, MobileNetV2 și Xception
- ❖ Set de date
 - 131 categorii de fructe și legume
 - 4 clase de fructe
 - 13 soiuri diferite de măr



STRUCTURĂ REȚEA NEURONALĂ

- ❖ Intrare: imagini cu fructe de dimensiune 100x100 pixeli
- ❖ 4 straturi convoluționale cu activare ReLU
- ❖ 4 straturi max-pool între straturile convoluționale
- ❖ un strat dens cu activare ReLU
- ❖ o funcție dropout
- ❖ un strat dens cu activarea softmax



Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 100, 100, 16)	448
max_pooling2d (MaxPooling2D)	(None, 50, 50, 16)	0
conv2d_1 (Conv2D)	(None, 50, 50, 32)	4640
max_pooling2d_1 (MaxPooling2D)	(None, 25, 25, 32)	0
conv2d_2 (Conv2D)	(None, 25, 25, 64)	18496
max_pooling2d_2 (MaxPooling2D)	(None, 12, 12, 64)	0
conv2d_3 (Conv2D)	(None, 12, 12, 128)	73856
max_pooling2d_3 (MaxPooling2D)	(None, 6, 6, 128)	0
flatten (Flatten)	(None, 4608)	0
dense (Dense)	(None, 256)	1179904
dropout (Dropout)	(None, 256)	0
dense_1 (Dense)	(None, 13)	3341
Total params: 1,280,685		
Trainable params: 1,280,685		
Non-trainable params: 0		

TRANSFER DE ÎNVĂȚARE

Transfer de învățare constă în preluarea caracteristicilor învățate cu privire la o problemă și utilizarea acestora într-o nouă problemă similară.

Pasul 1

Obținerea de straturi dintr-un model antrenat anterior

Pasul 2

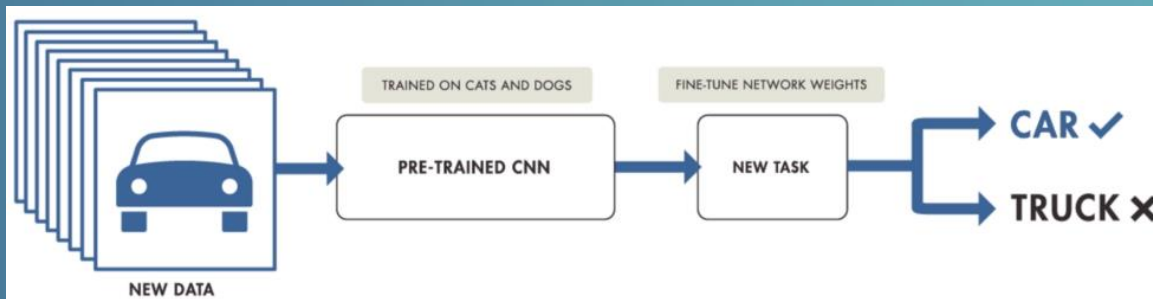
Înghețarea straturilor

Pasul 3


Adăugarea de straturi noi antrenabile deasupra celor înghețate

Pasul 4

Instruirea noilor straturi pe setul de date



BENEFICII TRANSFER DE ÎNVĂȚARE



Un început mai înalt
O pantă mai înaltă
O asimptotă mai înaltă

MODELELE PROPUSE

	DIMENSIUNE	TOP-1 ACURATEȚE	TOP-5 ACURATEȚE	ADÂNCIME
Xception	88 MB	0.790	0.945	126
VGG-16	528 MB	0.713	0.901	23
MobileNetV2	14 MB	0.713	0.901	88

SET DE DATE

FRUITS-360

Conține 131 clase cu fructe și este balansat.
Fundalul imaginilor este alb uniform.


Este împărțit în 75% set de antrenare și 25% set de testare.

Setul de antrenare este împărțit în 90% set de antrenare și 10% set de validare.

La preprocesarea setului de date am folosit vertical flip și orizontal flip. Am normalizat tot setul de date la valori între 0-1.



SET DE TESTARE



Set de testare care conține
imagini cu portocale, mere,
pere și banane.
Este împărțit în set de
testare cu fructe bine
încadrate și set de testare
cu fructe neîncadrate.



CONFIGURAȚIE

Toate modelele sunt antrenate cu optimizatorul Adam și callback-ul ReduceLROnPlateau cu rata de așteptare de 3 epoci și factor de reducere a învățării de 0.5.

Modelele CNN sunt antrenate la 50 de epoci.

Modelele cu transfer de învățare sunt antrenate la 50 de epoci în prima etapă, iar în a doua etapă până la un maxim de 75 de epoci cu callback-ul Earlystopping și o rată de învățare foarte mică.






CLASIFICAREA SOIURILOR DE MERE



CONFIGURAȚII

- ❖ Un strat dens cu funcția softmax cu 13 unități
- ❖ Un strat dens cu funcția de activare ReLU cu 256 de unități
- ❖ Dropout de 20%
- ❖ Un strat dens cu funcția softmax cu 13 unități
- ❖ Un strat dens cu funcția de activare ReLU cu 512 de unități
- ❖ Dropout de 20%
- ❖ Un strat dens cu funcția de activare ReLU cu 256 de unități
- ❖ Dropout de 20%
- ❖ Un strat dens cu funcția softmax cu 13 unități




ACURATEȚE

Model	Simpleu	Un strat	Două straturi
CNN	0.9724	0.9813	0.9709
VGG-16	0.9827	0.9902	0.9799
VGG-16 FT	0.9986	0.9836	0.9855
MobileNetV2	0.9072	0.9545	0.9428
MobileNetV2 FT	0.9442	0.9700	0.9574
Xception	0.9128	0.9063	0.9096
Xception FT	0.9110	0.9274	0.9063

ACURATEȚE








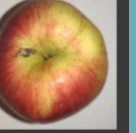

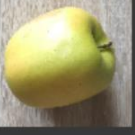



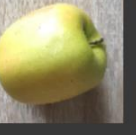




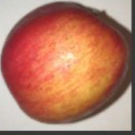
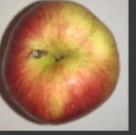


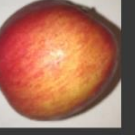
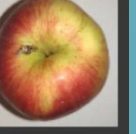





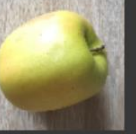


Model	Simpleu	Un strat	Două straturi
CNN	0.9724	0.9813	0.9709
VGG-16	0.9827	0.9902	0.9799
VGG-16 FT	0.9986	0.9836	0.9855
MobileNetV2	0.9072	0.9545	0.9428
MobileNetV2 FT	0.9442	0.9700	0.9574
Xception	0.9128	0.9063	0.9096
Xception FT	0.9110	0.9274	0.9063

IMAGINI NOI



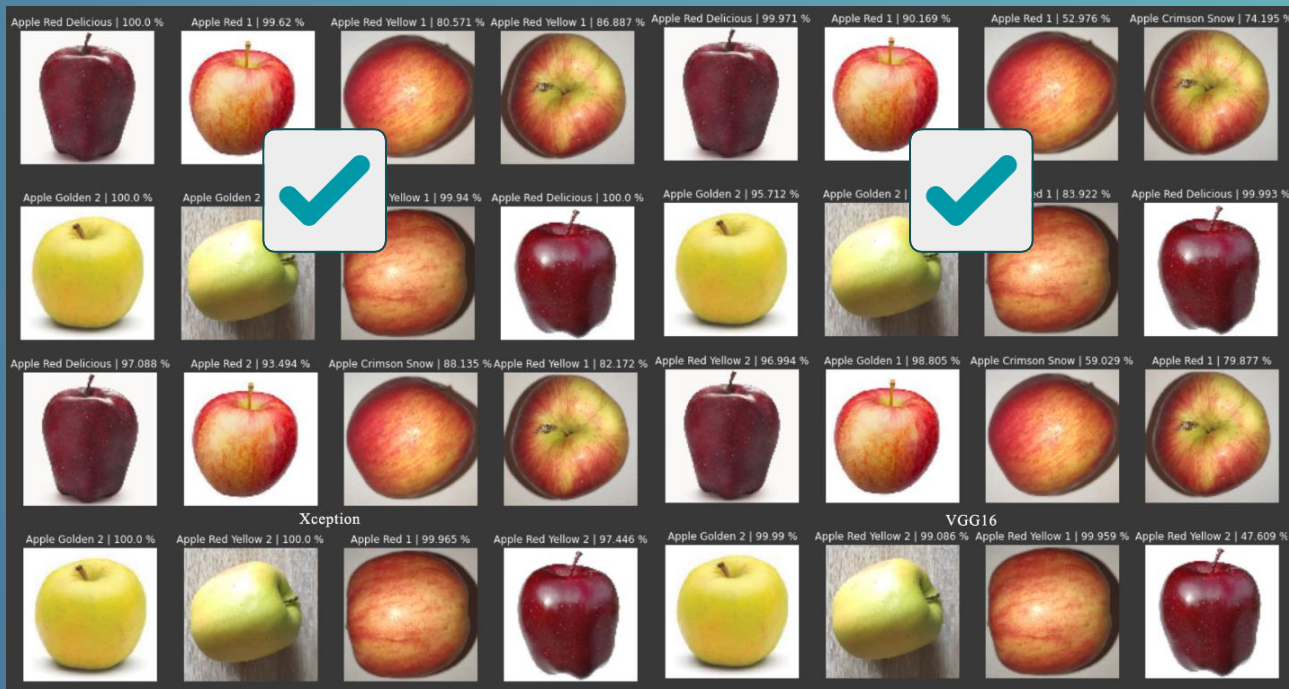
IMAGINI NOI

Mărul golden cu fundal alb este clasificat corect cu acuratețe între 95%-100%.

Apple Red Delicious 100.0 %	Apple Red 1 99.62 %	Apple Red Yellow 1 80.571 %	Apple Red Yellow 1 86.887 %	Apple Red Delicious 99.971 %	Apple Red 1 90.169 %	Apple Red 1 52.976 %	Apple Crimson Snow 74.195 %
							
CNN				MobileNetV2			
Apple Golden 2 100.0 %	Apple Golden 2 100.0 %	Apple Red Yellow 1 99.94 %	Apple Red Delicious 100.0 %	Apple Golden 2 95.712 %	Apple Golden 2 75.948 %	Apple Red 1 83.922 %	Apple Red Delicious 99.993 %
							
Apple Red Delicious 97.088 %	Apple Red 2 93.494 %	Apple Crimson Snow 88.135 %	Apple Red Yellow 1 82.172 %	Apple Red Yellow 2 96.994 %	Apple Golden 1 98.805 %	Apple Crimson Snow 59.029 %	Apple Red 1 79.877 %
							
Xception				VGG16			
Apple Golden 2 100.0 %	Apple Red Yellow 2 100.0 %	Apple Red 1 99.965 %	Apple Red Yellow 2 97.446 %	Apple Golden 2 99.99 %	Apple Red Yellow 2 99.086 %	Apple Red Yellow 1 99.959 %	Apple Red Yellow 2 47.609 %
							


IMAGINI NOI

Cele mai multe mere au fost clasificate corect de către MobileNetV2 și CNN.




IMAGINI NOI

CNN a prezis aceeași categorie în cele 3 imagini cu același măr.




IMAGINI NOI

Modelele Xception și VGG-16 clasifică incorect mărul golden de pe masă cu un măr roșu galben.



IMAGINI NOI

Modelul VGG-16 clasifică incorect mărul roșu delicios cu mărul roșu galben.






CLASIFICAREA TIPURILOR DE FRUCTE

SET DE DATE

NUMĂRUL DE IMAGINI DIN FIECARE CLASĂ



CONFIGURAȚIE

- ❖ Un strat dens cu funcția de activare ReLU cu 256 de unități
 - ❖ Dropout de 20%
- ❖ Un strat dens cu funcția softmax cu 13 unități

Seturi de testare:

- ❖ Cu fructe bine încadrate
- ❖ Cu fructe neîncadrate



ACURATEȚE

		Set de testare		Set de testare	Set de testare
		Simplu	Nebalansat	neîncadrat	bine încadrat
CNN	Simplu	1.000	-	0.2195	0.5122
	Undersampling	-	0.9884	0.4390	0.9756
	Nebalansat	-	0.9903	0.4878	0.9756
MobileNetV2	Simplu	1.000	0.7642	0.8293	0.8049
	Undersampling	1.000	0.9919	0.8537	0.9512
	Nebalansat	1.000	0.9986	0.9024	0.9756
MobileNetV2 fine-tuned	Simplu	1.000	0.7245	0.7561	0.8293
	Undersampling	1.000	0.9909	0.7561	0.8780
	Nebalansat	1.000	0.9982	0.8293	0.9512

ACURATEȚE

		Set de testare		Set de testare	Set de testare
		Simplu	Nebalansat	neîncadrat	bine încadrat
CNN	Simplu	1.000	-	0.2195	0.5122
	Undersampling	-	0.9884	0.4390	0.9756
	Nebalansat	-	0.9903	0.4878	0.9756
MobileNetV2	Simplu	1.000	0.7642	0.8293	0.8049
	Undersampling	1.000	0.9919	0.8537	0.9512
	Nebalansat	1.000	0.9986	0.9024	0.9756
MobileNetV2 fine-tuned	Simplu	1.000	0.7245	0.7561	0.8293
	Undersampling	1.000	0.9909	0.7561	0.8780
	Nebalansat	1.000	0.9982	0.8293	0.9512

ACURATEȚE

		Set de testare		Set de testare	Set de testare
		Simplu	Nebalansat	neîncadrat	bine încadrat
CNN	Simplu	1.000	-	0.2195	0.5122
	Undersampling	-	0.9884	0.4390	0.9756
	Nebalansat	-	0.9903	0.4878	0.9756
MobileNetV2	Simplu	1.000	0.7642	0.8293	0.8049
	Undersampling	1.000	0.9919	0.8537	0.9512
	Nebalansat	1.000	0.9986	0.9024	0.9756
MobileNetV2 fine-tuned	Simplu	1.000	0.7245	0.7561	0.8293
	Undersampling	1.000	0.9909	0.7561	0.8780
	Nebalansat	1.000	0.9982	0.8293	0.9512

ACURATEȚE

		Set de testare		Set de testare	Set de testare
		Simplu	Nebalansat	neîncadrat	bine încadrat
CNN	Simplu	1.000	-	0.2195	0.5122
	Undersampling	-	0.9884	0.4390	0.9756
	Nebalansat	-	0.9903	0.4878	0.9756
MobileNetV2	Simplu	1.000	0.7642	0.8293	0.8049
	Undersampling	1.000	0.9919	0.8537	0.9512
	Nebalansat	1.000	0.9986	0.9024	0.9756
MobileNetV2 fine-tuned	Simplu	1.000	0.7245	0.7561	0.8293
	Undersampling	1.000	0.9909	0.7561	0.8780
	Nebalansat	1.000	0.9982	0.8293	0.9512

ACURATEȚE

		Set de testare		Set de testare	Set de testare
		Simplu	Nebalansat	neîncadrat	bine încadrat
CNN	Simplu	1.000	-	0.2195	0.5122
	Undersampling	-	0.9884	0.4390	0.9756
	Nebalansat	-	0.9903	0.4878	0.9756
MobileNetV2	Simplu	1.000	0.7642	0.8293	0.8049
	Undersampling	1.000	0.9919	0.8537	0.9512
	Nebalansat	1.000	0.9986	0.9024	0.9756
MobileNetV2 fine-tuned	Simplu	1.000	0.7245	0.7561	0.8293
	Undersampling	1.000	0.9909	0.7561	0.8780
	Nebalansat	1.000	0.9982	0.8293	0.9512

CLASIFICĂRI INCORECTE

Nebalansat

Pear | 98.523 %



Pear | 100.0 %



Undersampling

Pear | 99.916 %



Pear | 100.0 %



Pear | 86.354 %



CNN

Prima imagine prezisă incorect de modelul antrenat pe setul nebalansat. A doua imagine prezisă incorect de modelul antrenat pe setul cu metoda undersampling.

MobileNetV2

Prima imagine prezisă incorect de modelul antrenat pe setul nebalansat. Ultimele două imagini prezise incorect de modelul antrenat pe setul cu metoda undersampling.



CLASIFICARE 131 TIPURI DE FRUCTE

CONFIGURAȚIE

Configurație

- ❖ Un strat dens cu funcția de activare ReLU cu 256 de unități
 - ❖ Dropout de 20%
- ❖ Un strat dens cu funcția softmax cu 13 unități



ACURATEȚE

Modele	loss	accuracy
CNN cu 50 de epoci	0.1985	0.9833
VGG-16 cu 50 de epoci	0.1496	0.9759
VGG-16 cu 54 de epoci	0.1478	0.9721
Xception cu 50 de epoci	0.5435	0.9485
Xception cu 68 de epoci	0.1627	0.9784
MobileNetV2 cu 50 de epoci	0.3572	0.9680
MobileNetV2 cu 56 de epoci	0.2329	0.9726

ACURATEȚE

Modele	loss	accuracy
CNN cu 50 de epoci	0.1985	0.9833
VGG-16 cu 50 de epoci	0.1496	0.9759
VGG-16 cu 54 de epoci	0.1478	0.9721
Xception cu 50 de epoci	0.5435	0.9485
Xception cu 68 de epoci	0.1627	0.9784
MobileNetV2 cu 50 de epoci	0.3572	0.9680
MobileNetV2 cu 56 de epoci	0.2329	0.9726


ACURATEȚE

Modele	loss	accuracy
CNN cu 50 de epoci	0.1985	0.9833
VGG-16 cu 50 de epoci	0.1496	0.9759
VGG-16 cu 54 de epoci	0.1478	0.9721
Xception cu 50 de epoci	0.5435	0.9485
Xception cu 68 de epoci	0.1627	0.9784
MobileNetV2 cu 50 de epoci	0.3572	0.9680
MobileNetV2 cu 56 de epoci	0.2329	0.9726


ACURATEȚE

Modele	loss	accuracy
CNN cu 50 de epoci	0.1985	0.9833
VGG-16 cu 50 de epoci	0.1496	0.9759
VGG-16 cu 54 de epoci	0.1478	0.9721
Xception cu 50 de epoci	0.5435	0.9485
Xception cu 68 de epoci	0.1627	0.9784
MobileNetV2 cu 50 de epoci	0.3572	0.9680
MobileNetV2 cu 56 de epoci	0.2329	0.9726

IMAGINI NOI



IMAGINI NOI






















Abstract geometric patterns in the top corners of the slide, consisting of white lines connecting dots to form various polygonal shapes.

VA MULȚUMESC!